Predikce tržního podílu televizních stanic

Bc. Adam Čech

Data Science Assignment

9. března 2026

Obsah prezentace

1. Analýza dat (Task 1)
   - Vhled do dat (EDA)
2. Modelování bez baseline (Task 2)
   - Metodika a Workflow
   - Výsledky modelu
3. Optimalizace a interpretace (Task 3)
   - Vliv 3M průměru
   - Analýza chyb
4. Inženýrský pohled (Task 4)
   - Náklady a MLOps
5. Závěr
   - Budoucí kroky

Analýza čtyř TV kanálů

Cílem první části bylo analyzovat historická data sledovanosti (share 15-54) pro vybrané kanály a identifikovat vzorce chování diváků.

- **Periodicita:** Identifikována silná denní (prime-time) a týdenní sezónnost.
- **Dominance:** Kanál ID 3 vykazuje nejvyšší průměrný share, zatímco kanál ID 54 je stabilní s nižším zásahem.
- **Atributy:** Původ obsahu (CZ/SK vs. zahraniční) se jeví jako silný indikátor budoucího úspěchu slotu.

Analýza sledovanosti: Kanál 3 (Heatmapa)

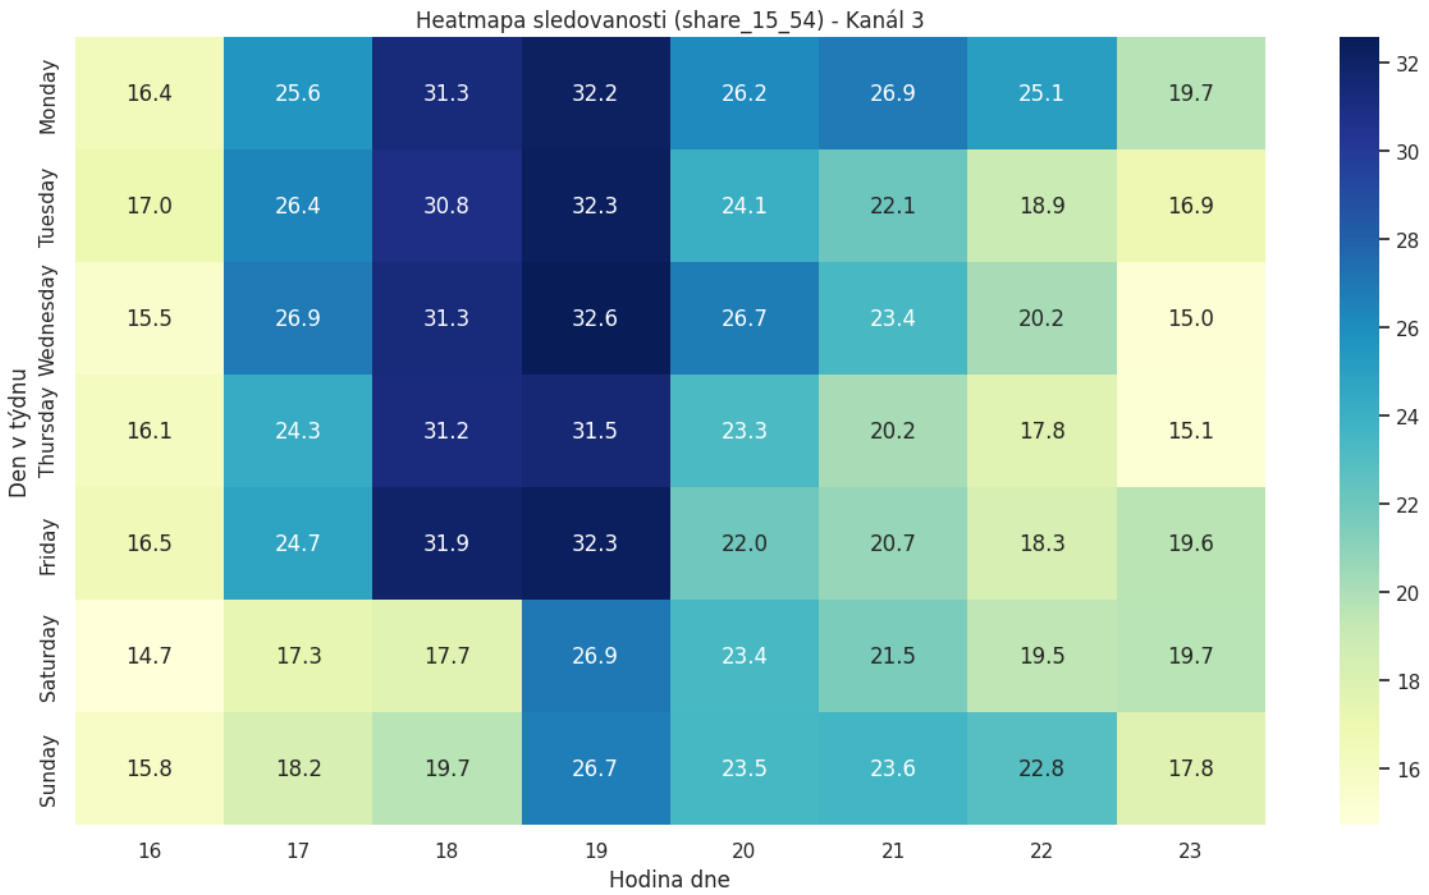

Analýza sledovanosti: Kanál 3 (Heatmapa)

- **Prime-time dominance:** Nejsilnější zásah mezi 18:00 a 20:00 s tržním podílem přesahujícím 32 %.
- **Stabilita všedních dnů:** Konzistentní špičky v pracovním týdnu naznačují fixní programové schéma (např. hlavní zprávy/seriály).
- **Víkendový posun:** V sobotu a neděli začíná nárůst sledovanosti později, s vrcholem posunutým k 20. hodině.
- **Implikace pro model:** Silná závislost na hodině a dni potvrzuje správnost použití cyklických časových příznaků (sin / cos).

Analýza sledovanosti: Kanál 4 (Heatmapa)

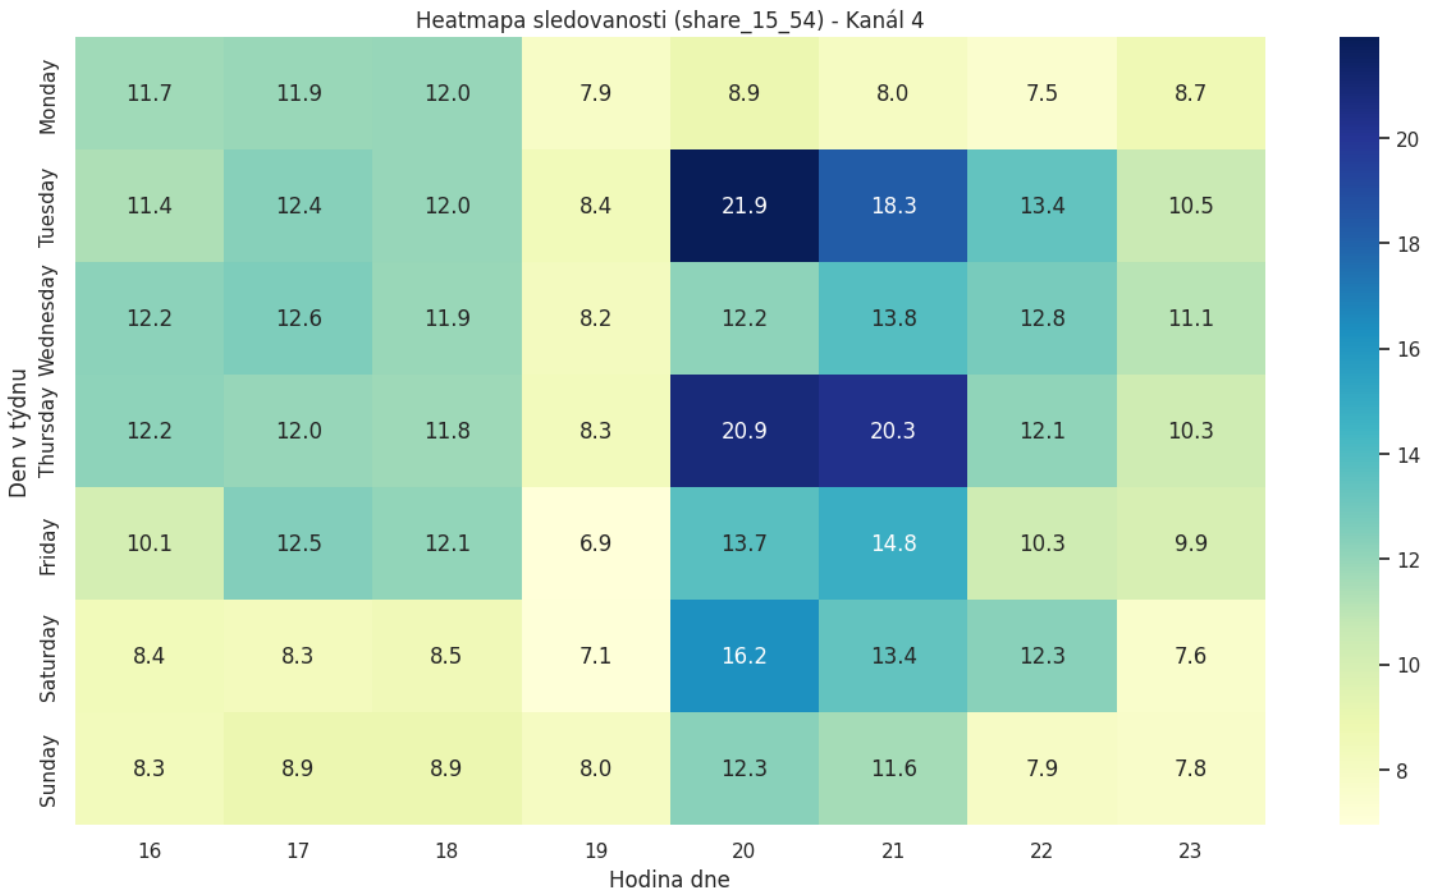

Analýza sledovanosti: Kanál 4 (Heatmapa)

- **Specifické špičky (Tuesday/Thursday):** Na rozdíl od Kanálu 3 vykazuje tento kanál extrémní nárůst sledovanosti (přes 20 %) pouze v úterý a čtvrtek mezi 20:00 a 21:00.
- **Programová selektivita:** Ostatní dny zůstávají v prime-time na polovičních hodnotách, což značí silnou vazbu na konkrétní vysílaný pořad (např. premiérový seriál).
- **Výzva pro model (Task 2):** V grafu predikcí (*image4.jpg*) vidíme, že model tyto specifické úterní/čtvrteční "výstřely" zachycuje jen částečně, protože mu chybí informace o konkrétním titulu.

Analýza trendů: Dlouhodobý vývoj tržního podílu

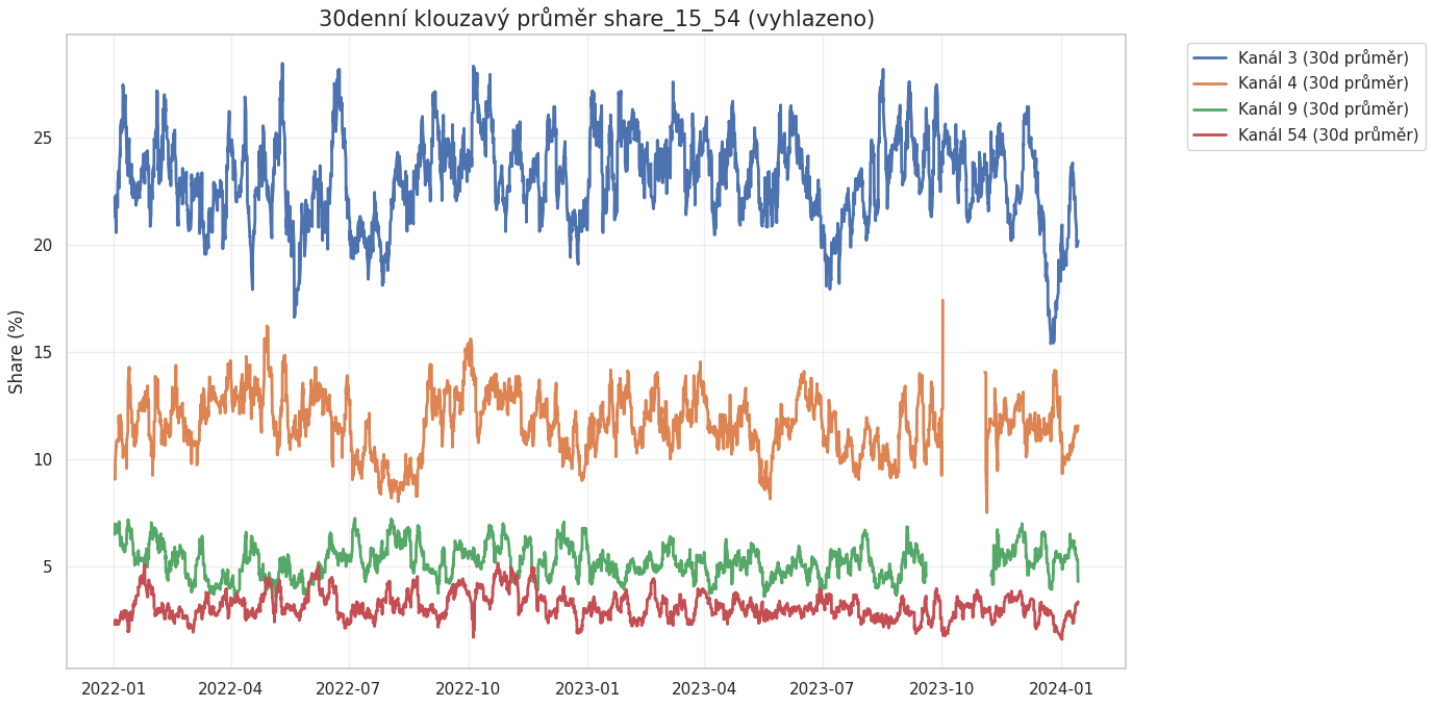

Analýza trendů: Dlouhodobý vývoj tržního podílu

- **Hierarchie kanálů:** Jasná a stabilní dominance **Kanálu 3**, který se dlouhodobě pohybuje mezi 20–28 % share.
- **Stabilita trhu:** Navzdory lokálním výkyvům vykazují všechny kanály (zejména 9 a 54) vysokou míru dlouhodobé stability bez výrazných strukturálních změn.
- **Sezónní korelace:** Patrné jsou společné trendy (např. poklesy v letních měsících), což potvrzuje vliv globálních faktorů na celé portfolio.
- **Význam pro model:** Tato data obhajují zařazení **3měsíčního průměru** jako baseline příznaku v Tasku 3, který pomáhá modelu zachytit tuto dlouhodobou hladinu.

Příprava příznaků a volba modelu

- **Cyklické kódování:** Hodiny převedeny na sin a cos složky pro zachování kontinuity času.
- **Validace:** Použit `TimeSeriesSplit` (5 foldů) pro simulaci reálného nasazení a zamezení úniku dat z budoucnosti.
- **Model:** Zvolen **XGBoost Regressor** pro jeho efektivitu při práci s nelineárními vztahy a tabulkovými daty.
- **Ladění:** Hyperparametry optimalizovány pomocí knihovny *Optuna* (15 trials).

Kvantitativní výsledky (Task 2)

Model bez znalosti dlouhodobého průměru vykazuje vysokou přesnost:

- **Průměrná MAE:** 2.5438 %
- **Adjusted R^2:** 0.8522
- **Interpretace:** Model vysvětluje 85 % variability trhu pouze na základě času, identity kanálu a historie z posledních 24 hodin.

Vylepšení pomocí baseline (Task 3)

- Do modelu přidán příznak `share_15_54_3mo_mean`.
- **Zlepšení přesnosti:** MAE klesla na 2.5273 %.
- **Stabilizace:** Dlouhodobý průměr funguje jako "kotva", která zpřesňuje predikce v obdobích s nízkou volatilitou.
- **Význam příznaků:** Podle Feature Importance se tento průměr stal 3. nejdůležitějším faktorem.

Kde model selhává? (Error Analysis)

- **Podstřelování špiček:** Model má tendenci k regresi k průměru. Extrémní úspěchy (blockbustery) podceňuje.
- **Příčina:** Absence metadat o obsahu (názvy filmů, premiéry, sportovní události).
- **Vizuální shoda:** Predikce věrně kopíruje denní cyklus, ale nedosahuje na absolutní maxima sledovanosti.

Kde model selhává? (Error Analysis)

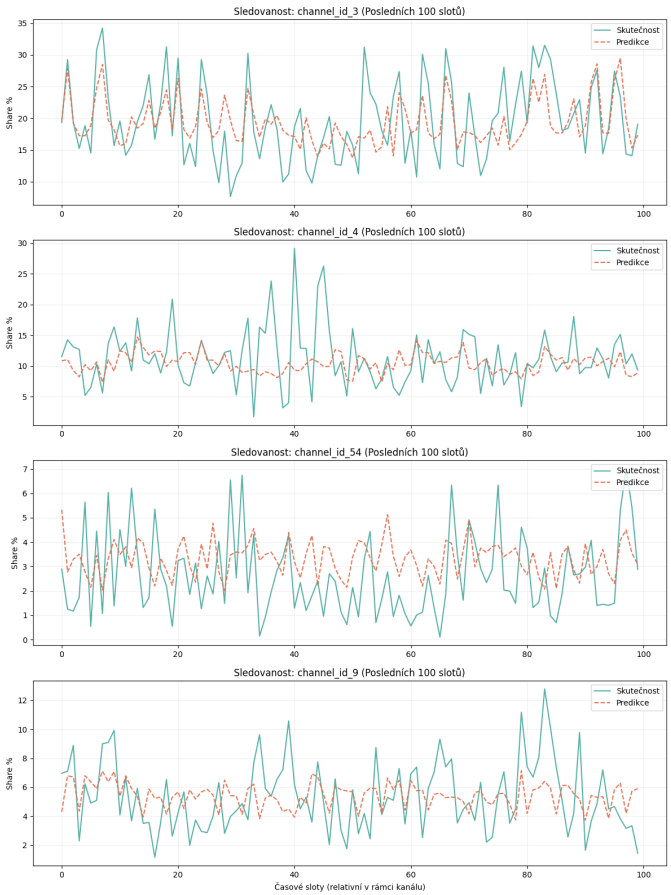

Produkční nasazení a škálovatelnost

- **Náklady:** Trénink XGBoost je extrémně levný (CPU jednotky minut), inference trvá řádově milisekundy.
- **Docker:** Kontejnerizace modelu zajišťuje reprodukovatelnost na libovolném OS.
- **Orchestrace:** Návrh na denní automatické přetrénování s verzováním v MLflow.
- **REST API:** Vystavení endpointu přes FastAPI pro reálné předpovídání.

Roadmapa vylepšení

- **Externí data:** Integrace počasí a sociálních sítí (hashtagy k pořadům).
- **NLP analýza:** Scraping recenzí z ČSFD pro sémantickou analýzu atraktivity titulů.
- **Ensemble:** Spojení více modelů (např. CatBoost + XGBoost) pro zvýšení robustnosti.
- **Monitoring:** Sledování datového driftu a degradace přesnosti v čase.

Poděkování

Děkuji za pozornost!

Dotazy?